

Μηχανές Αναζήτησης και Ανάλυση Κειμένου

2025-2026

Άννα Ζερβάκη

AM: ics21122

Προγραμματιστική Εργασία 2

Α.Περιγραφή κάθε pipeline και επιλογών προεπεξεργασίας

Στο πλαίσιο της παρούσας εργασίας, η ροή επεξεργασίας (pipeline) σχεδιάστηκε με γνώμονα τη συστηματική μετατροπή του ακατέργαστου κειμένου σε μια μορφή κατάλληλη για την εκπαίδευση αλγορίθμων μηχανικής μάθησης. Η διαδικασία ξεκινά με τη φόρτωση των δεδομένων από το σύνολο `txt_sentoken`, όπου χρησιμοποιήθηκε η μέθοδος `load_files` ή η προσαρμοσμένη συνάρτηση `load_data` για την αυτόματη ομαδοποίηση των 2.000 κριτικών στους υποφακέλους `pos` (θετικές) και `neg` (αρνητικές).

Το κρίσιμότερο στάδιο του pipeline αφορά την προεπεξεργασία του κειμένου (Preprocessing), η οποία υλοποιήθηκε κυρίως μέσω της συνάρτησης `baseline_preprocess` με τη χρήση της βιβλιοθήκης NLTK. Αρχικά, πραγματοποιήθηκε μετατροπή όλων των χαρακτήρων σε πεζά (`lowercasing`), διασφαλίζοντας ότι λέξεις με διαφορετική χρήση κεφαλαίων (π.χ. "Excellent" και "excellent") θα αντιμετωπίζονται ως η ίδια οντότητα. Ακολούθησε ο χωρισμός των κειμένων σε μεμονωμένες μονάδες (tokens) μέσω της διαδικασίας του `tokenization`.

Προκειμένου να μειωθεί ο θόρυβος στα δεδομένα, εφαρμόστηκαν αυστηρά φίλτρα καθαρισμού. Αφαιρέθηκαν όλα τα σημεία στίξης και οι ειδικοί χαρακτήρες κρατώντας μόνο αλφαβητικά tokens μέσω της μεθόδου `isAlpha()`, καθώς τα νούμερα και τα σύμβολα σε κριτικές ταινιών σπάνια φέρουν ουσιαστική πληροφορία για το συναίσθημα. Παράλληλα,

απομακρύνθηκαν οι λέξεις που ανήκουν στην προκαθορισμένη λίστα των stopwords της αγγλικής γλώσσας. Είναι πολύ σημαντικό να αφαιρεθούν καθώς λέξεις όπως "the", "is" ή "and" εμφανίζονται με πολύ υψηλή συχνότητα όμως δεν μας λένε απολύτως τίποτα για το αν μια κριτική είναι θετική ή αρνητική.

Μετά τον καθαρισμό, τα δεδομένα πέρασαν στο στάδιο της διανυσματικής αναπαράστασης (Vectorization). Δοκιμάστηκαν τέσσερις διαφορετικές προσεγγίσεις: η Δυαδική αναπαράσταση (Binary - E1), η αναπαράσταση Πλήθους Εμφανίσεων (Term Frequency - E2) και η μέθοδος TF-IDF (E3). Επιπλέον, εξετάστηκε η χρήση Word Embeddings μέσω του μοντέλου Word2Vec (E4) με τη μέθοδο του mean pooling. Η επιλογή του Word2Vec έγινε ως μια πιο σύγχρονη προσέγγιση που λαμβάνει υπόψη τη σημασιολογική εγγύτητα των λέξεων και όχι μόνο την ακριβή τους εμφάνιση.

Για την αξιολόγηση των μοντέλων Naive Bayes, έγινε σύγκριση μεταξύ των παραλλαγών Multinomial (K1) και Bernoulli (K2), καθώς και του Binarized Multinomial (K3). Η σύγκριση αυτή επέτρεψε να διαπιστωθεί αν η συχνότητα των λέξεων παίζει μεγαλύτερο ρόλο από την απλή παρουσία τους, με τον K3 να επιτυγχάνει την υψηλότερη ακρίβεια (0.838). Τέλος, ολόκληρο το pipeline ενσωματώθηκε σε μια διαδικασία 5-fold cross-validation μέσω των StratifiedKFold ή cross_validate, ώστε να διασφαλιστεί ότι τα αποτελέσματα είναι γενικεύσιμα και δεν οφείλονται σε τυχαία κατανομή των δεδομένων.

B. Σύγκριση NB Παραλλαγών και Νέων Γλωσσικών Τεχνικών

Σε αυτό το στάδιο της εργασίας, το ενδιαφέρον μετατοπίστηκε από την απλή επεξεργασία των λέξεων στην ενσωμάτωση γλωσσικής πληροφορίας, με στόχο τη βελτίωση της ακρίβειας του μοντέλου. Αρχικά, έγινε μια σύγκριση των παραλλαγών του Naive Bayes, όπου διαπιστώθηκε ότι η δυαδική αναπαράσταση σε συνδυασμό με τον Multinomial αλγόριθμο (K3+E1) απέδωσε την υψηλότερη ακρίβεια baseline (0.838).

Στη συνέχεια, εφαρμόστηκαν τρεις εξειδικευμένες γλωσσικές τεχνικές πάνω στο βασικό μοντέλο:

Διαχείριση Άρνησης (Negation handling): Επειδή λέξεις όπως το "good" αλλάζουν εντελώς νόημα όταν προηγείται μια άρνηση, υλοποιήθηκε μια συνάρτηση που προσθέτει το πρόθεμα NOT_ σε κάθε λέξη που ακολουθεί αρνητικούς όρους (όπως "not", "no", "never"). Αυτό επέτρεψε στον αλγόριθμο να αντιληφθεί ότι το "NOT_good" είναι μια ξεχωριστή οντότητα. Η τεχνική αυτή ανέβασε την ακρίβεια στο 0.815.

Στάθμιση με POS (Part-of-Speech Weights): Η λογική εδώ είναι ότι ορισμένα μέρη του λόγου, όπως τα επίθετα και τα επιρρήματα, μεταφέρουν πολύ περισσότερο συναίσθημα από ό,τι τα ουσιαστικά. Χρησιμοποιώντας το pos_tag του NLTK, έδωσα διπλάσιο βάρος (x2) σε αυτές τις κατηγορίες μέσα στον πίνακα συχνότητων. Η τεχνική αυτή αποδείχθηκε η πιο αποτελεσματική από τις τρεις, φτάνοντας το 0.831.

Στάθμιση βάσει Θέσης (Sentence Position): Θεωρώντας ότι οι κριτικοί ταινιών συχνά τοποθετούν τα πιο σημαντικά συμπεράσματά τους στην εισαγωγή ή στον επίλογο, έδωσα διπλάσιο βάρος (x2) στα tokens που εμφανίζονται στην πρώτη και την τελευταία πρόταση κάθε κειμένου. Η απόδοση εδώ ήταν 0.792.

Τέλος, εξετάστηκε το σενάριο του συνδυασμού όλων των παραπάνω τεχνικών, το οποίο απέδωσε 0.823. Παρόλο που ο συνδυασμός είναι ισχυρός, το γεγονός ότι η στάθμιση POS μόνη της πλησίασε περισσότερο το κορυφαίο μας baseline δείχνει ότι η ποιότητα των λέξεων (επίθετα) είναι συχνά πιο σημαντική από τη θέση τους μέσα στο κείμενο.

Ενότητα	Κωδικός	Περιγραφή Δοκιμής	Accuracy
Μέρος Α (Baseline)	K2 + E1	Bernoulli NB με Διαδική αναπαράσταση	0.788
	K3 + E1	Binarized Multinomial NB (Το καλύτερο Baseline)	0.838
	K1 + E2	Multinomial NB με Πλήθος εμφανίσεων (TF)	0.806
	K1 + E3	Multinomial NB με TF-IDF	0.821
Μέρος Β (Τεχνικές)	B.a	Σενάριο 2: Baseline + Διαχείριση Άρνησης	0.815
	B.b	Σενάριο 3: Baseline + Στάθμιση POS (x2)	0.831
	B.g	Σενάριο 4: Baseline + Στάθμιση Θέσης (x2)	0.792
	B.5	Σενάριο 5: Συνδυασμός Όλων των Τεχνικών	0.823

Γ.Σύγκριση RapidMiner με τη δική σας υλοποίηση

Στο τελευταίο στάδιο της εργασίας, πραγματοποιήθηκε σύγκριση της απόδοσης μεταξύ του περιβάλλοντος RapidMiner και της προσαρμοσμένης υλοποίησης σε Python. Τα αποτελέσματα παρουσιάζουν μια αξιοσημείωτη απόκλιση υπέρ της Python σε όλες τις κατηγορίες αναπαράστασης.

Αναπαράσταση	Python (Baseline)	RapidMiner	Διαφορά
Binary (Δυαδική)	83.8%	67.25%	+16.55%
Counts (Συχνότητα)	80.6%	65.85%	+14.75%
TF-IDF	82.1%	67.05%	+15.05%

Η μεγάλη διαφορά στην απόδοση οφείλεται κυρίως στο ότι η Python χρησιμοποιεί τον Multinomial Naive Bayes, που είναι ειδικά σχεδιασμένος για την επεξεργασία λέξεων, σε αντίθεση με τον πιο γενικό αλγόριθμο του RapidMiner που δυσκολεύεται με τη φύση των δεδομένων κειμένου. Παράλληλα, η υλοποίηση σε Python προσφέρει απόλυτο έλεγχο στην προεπεξεργασία, επιτρέποντας τον καθαρισμό του «θορύβου» και την πλήρη αξιοποίηση της δυαδικής αναπαράστασης, η οποία αποδείχθηκε η πλέον επιτυχημένη για το συγκεκριμένο dataset με ακρίβεια 83.8% έναντι 67.25%. Συμπερασματικά, η δυνατότητα προσαρμογής του κώδικα επέτρεψε τη δημιουργία ενός μοντέλου βελτιστοποιημένου για την ανάλυση συναισθήματος, ξεπερνώντας τις τυποποιημένες λύσεις του έτοιμου λογισμικού.